APPLIED DATA SCIENCE / NOVEMBER 2026

RETAILCAST

Evaluasi Peramalan Penjualan Retail dan Simulasi Keputusan Kapasitas Persediaan

Studi Eksploratif Berbasis UCI Online Retail II | 50 SKU | 104 Minggu

DESAIN PENELITIAN	IMPLEMENTASI
Rolling one-week-ahead forecast	Dashboard interaktif berbasis Streamlit
40 minggu validasi + 12 minggu holdout	GitHub Actions • Python 3.13
MA4 • Ridge • Histogram Gradient Boosting	Simulasi indeks penalti 1:1, 3:1, 5:1

Penyusun Zaky Ilham Ferdiansyah

Afiliasi Program Studi Teknik Informatika, Universitas Dian Nuswantoro

Versi dokumen Draf laporan penelitian terapan v1.0 — 7 November 2026

Demo publik https://retailcast-research-zaky.streamlit.app/

Repositori https://github.com/zakyilhamf647586-spec/retailcast-research-dashboard

PERNYATAAN RUANG LINGKUP

Laporan ini menyajikan hasil pengujian historis dan simulasi eksploratif. Ini bukan artikel yang telah ditelaah sejawat, bukan sistem inventori operasional, dan bukan bukti penghematan biaya nyata.

Abstrak

Prediksi penjualan menjadi komponen penting untuk mendukung perencanaan kapasitas persediaan. Penelitian terapan ini membandingkan metode moving average empat minggu (MA4), Ridge Regression, dan Histogram Gradient Boosting untuk memprediksi unit penjualan positif yang tercatat per produk satu minggu ke depan. Data Online Retail II dari UCI terdiri atas 1.067.371 baris item transaksi periode 2009–2011, yang diproses menjadi panel 50 SKU selama 104 minggu lengkap. Pemilihan SKU berbasis 52 minggu awal diikuti validasi rolling 40 minggu dan evaluasi holdout akhir 12 minggu. MA4 memperoleh WAPE validasi 73,6334% dan menjadi metode utama yang dipilih sebelum holdout. Pada holdout, Ridge mencatat WAPE 53,4649%, dibanding MA4 54,0980%; selisih kecil tersebut belum memberikan bukti kuat superioritas berdasarkan analisis ketidakpastian deskriptif. Simulasi kapasitas satu periode dengan rasio penalti kekurangan:kelebihan 3:1 menghasilkan indeks 256.486 untuk MA4 berpenyesuaian kuantil versus 277.905 pada MA4 mentah, namun perbandingan kebijakan ini dirancang setelah holdout dilihat dan karenanya bersifat post-hoc. Prototipe dashboard publik menyajikan hasil, batasan, dan keterlacakan data. Studi menunjukkan pentingnya baseline, evaluasi temporal, dan pelaporan hasil negatif secara jujur; belum ada validasi keputusan stok aktual.

Kata kunci Peramalan penjualan; rolling-origin; WAPE; Ridge Regression; forecasting baseline; newsvendor; transparansi penelitian.

Ringkasan eksekutif

DIMENSI	HASIL PENELITIAN
Dataset	1.067.371 item transaksi; 50 SKU terpilih
Periode evaluasi	40 minggu validasi + 12 minggu holdout
Metode terpilih saat validasi	MA4; WAPE 73,6334%
Model terbaik secara titik pada holdout	Ridge; WAPE 53,4649% (vs MA4 54,0980%)
Simulasi 3:1 (eksploratif)	MA4 kuantil 256.486 vs MA4 raw 277.905 (−7,71%)
Deployment	https://retailcast-research-zaky.streamlit.app/
Audit data	Gate 2A bersyarat; transaksi identik & bulk belum direkonsiliasi

1. Pendahuluan

Peramalan penjualan membantu organisasi memperkirakan beban operasional dan kebutuhan kapasitas. Namun, penggunaan algoritma yang lebih kompleks tidak otomatis menghasilkan prediksi yang lebih berguna. Karena itu, RETAILCAST menempatkan baseline sederhana dan protokol evaluasi temporal sebagai tolok ukur bagi model supervisi yang lebih kompleks.

Konteks bisnis studi dibatasi oleh data historis retail asal Inggris, tanpa catatan stok aktual atau permintaan yang tidak terpenuhi. Dengan demikian penelitian ini menyelidiki keterkaitan antara ketepatan prediksi unit penjualan tercatat dan keputusan kapasitas hipotetis, bukan melakukan optimasi pengadaan barang perusahaan.

1.1 Rumusan masalah

- Bagaimana perbandingan kinerja MA4, Ridge, dan Histogram Gradient Boosting pada rolling one-week-ahead forecast?
- Apakah performa pada validasi sejalan dengan performa pada holdout terakhir yang belum digunakan untuk pemilihan metode?
- Bagaimana pilihan fungsi penalti dan koreksi residual memengaruhi hasil simulasi kapasitas satu periode?

2. Data, Audit, dan Definisi Target

Sumber adalah Online Retail II dari UCI Machine Learning Repository, yang memuat transaksi ritel non-toko di Inggris pada 1 Desember 2009 hingga 9 Desember 2011. Dataset memperoleh atribusi kepada Daqing Chen, DOI 10.24432/C5CG6D, dan lisensi CC BY 4.0 [1]. Unit mentah adalah item transaksi, bukan transaksi pelanggan independen.

TEMUAN AUDIT	JUMLAH / CATATAN
Baris mentah	1.067.371
Invoice unik	53.628
StockCode unik	5.131
Pembatalan (invoice diawali C)	19.494 baris
Quantity tidak positif	22.950 baris
Duplikat persis terdeteksi	34.335 baris (tidak dihapus otomatis)
Baris lolos filter awal penjualan positif	1.035.621
Panel tetap	50 SKU × 104 minggu = 5.200 baris

2.1 Definisi target dan sampel

Target y(i,t) adalah jumlah unit penjualan POSITIF TERCATAT untuk produk i pada minggu lengkap Senin–Minggu t. Pembatalan, pengembalian, dan transaksi nonpositif tidak dinetokan ke target; ketiadaan penjualan tidak membuktikan ketiadaan permintaan. Pemilihan 50 SKU memakai hanya 52 minggu awal, dengan kriteria eksploratif aktif minimal 26 minggu dan tidak ada satu minggu yang menyumbang lebih dari 50% volume setahun awal.

2.2 Kualitas data dan potensi bias

Audit tindak lanjut pada kelompok 50 SKU sebelum holdout menunjukkan 2.263 baris identik dengan kontribusi 2,284% unit, serta 123 baris dengan quantity ≥1.000 menyumbang 13,440% unit. Ini mengidentifikasi potensi sensitivitas, bukan membuktikan kesalahan data. Aturan format StockCode yang dipakai juga dapat mengecualikan produk sah dengan sufiks lebih panjang, seperti 15056BL. Semua aturan dan risiko ini dipertahankan sebagai pembatasan inferensi, tanpa revisi data setelah hasil holdout diketahui.

2.3 Status Gate 2A

Gate audit berkategori BERSYARAT untuk demonstrasi penelitian historis. Penutupan audit penuh memerlukan dokumen invoice asli, katalog SKU otoritatif, serta bukti transaksi grosir dan retur dari

sistem sumber. Bukti tersebut tidak tersedia dalam dataset publik. Mengubah pembersihan sekarang akan mengubah populasi penelitian dan menuntut evaluasi independen baru.

3. Metodologi Eksperimen

Desain menggunakan rolling-origin satu minggu ke depan. Observasi aktual dari minggu yang telah selesai boleh dipakai pada origin berikutnya, tetapi prediksi minggu t tidak boleh mengakses target minggu t atau sesudahnya. Penelitian tidak memakai pembagian acak untuk data deret waktu.

BAGIAN	RENTANG	FUNGSI
52 minggu awal	7 Des 2009–5 Des 2010	Seleksi SKU dan pembentukan riwayat
40 minggu validasi	6 Des 2010–11 Sep 2011	Perbandingan serta pemilihan metode
12 minggu holdout	12 Sep–4 Des 2011	Evaluasi final satu kali

3.1 Model pembanding

- Moving Average empat minggu: rata-rata penjualan pada t−1 hingga t−4; prediksi nonnegatif.
- Ridge Regression: fitur numerik diskalakan, SKU di-one-hot-encode, penalti α=100.
- Histogram Gradient Boosting: 125 iterasi, learning rate 0,055, maksimum 15 leaf nodes, minimum 35 sampel per leaf, regularisasi L2=10.

Model ML menggunakan lag t−1,2,3,4,8,12; rata-rata bergulir 4/8/12 minggu; median dan deviasi standar empat minggu; proporsi minggu nol; tren; komponen kalender; dan identitas SKU. Fitur berbasis target bergeser sehingga hanya melihat masa lalu. Pada tiap origin, model dilatih ulang menggunakan historis yang sudah tersedia.

3.2 Ukuran evaluasi

Metrik utama adalah WAPE = 100 × Σ|y−ŷ| / Σy, dihitung pada semua SKU-minggu dalam periode yang sama. Metrik tambahan adalah MAE, RMSE, bias (ŷ−y), serta macro-MASE yang merata-ratakan error terskala antar-SKU. WAPE bukan nilai akurasi; WAPE yang lebih rendah berarti kesalahan total relatif lebih kecil. Untuk pembandingan antarseri, MASE memiliki dukungan metodologis pada Hyndman & Koehler [2].

3.3 Ketidakpastian dan pembekuan protokol

Selisih antarmetode diperiksa menggunakan paired circular block bootstrap dengan blok empat minggu. Rentang resampling bersifat deskriptif; 12 minggu holdout terlalu pendek untuk klaim inferensial yang kuat. Pilihan MA4 dari validasi dipertahankan setelah holdout terlihat. Desain eksperimen tetap eksploratif, bukan preregistrasi penuh.

4. Hasil Forecasting

4.1 Validasi 40 minggu

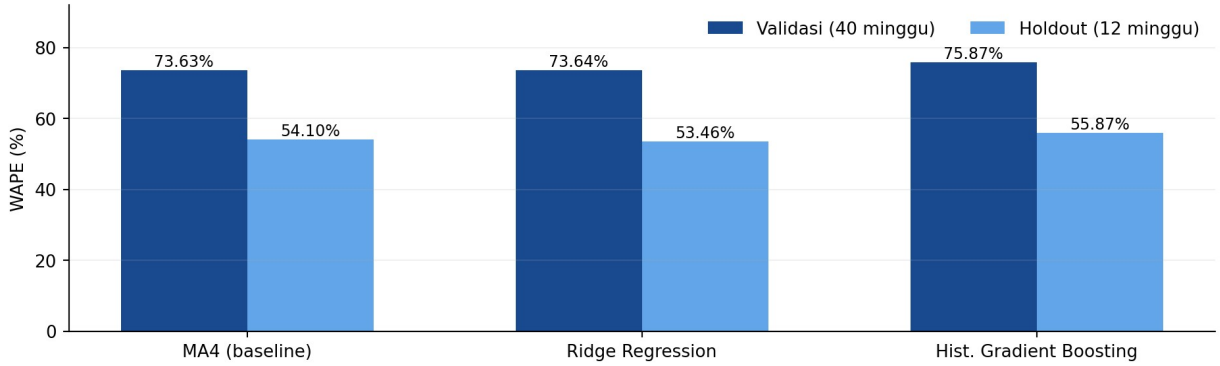
METODE	WAPE	MAE (unit)	RMSE
MA4	73,6334%	231,4123	411,6239
Ridge Regression	73,6373%	231,4244	396,0871
Hist. Gradient Boosting	75,8745%	238,4554	399,8160

MA4 memberikan WAPE terendah pada jendela validasi, tetapi Ridge hampir identik (selisih 0,0039 poin persentase). Ridge mengurangi RMSE namun tidak mengurangi WAPE; peringkat model bergantung pada tujuan evaluasi. MA4 tetap ditetapkan sebagai metode utama sebelum holdout dibuka.

4.2 Holdout final 12 minggu

METODE	WAPE	MAE (unit)	RMSE	MACRO-MASE
Ridge Regression	53,4649%	217,2901	399,7930	0,7360
MA4	54,0980%	219,8633	402,2866	0,7263
Hist. Gradient Boosting	55,8704%	227,0664	408,6208	0,7332

Setiap metode membuat 600 prediksi (50 SKU × 12 minggu), dengan total 243.850 unit aktual. Ridge memiliki WAPE 0,6332 poin persentase lebih rendah daripada MA4 pada holdout, tetapi interval bootstrap deskriptif selisih Ridge–MA4 sebesar [−1,7082; +0,5990] poin persentase masih mencakup nol. Hasil ini belum membuktikan superioritas, dan tidak menjadi alasan mengubah model final yang dipilih sebelumnya.



Gambar 1. WAPE per metode: validasi dan holdout mempunyai komposisi waktu berbeda.

WAPE holdout yang tampak lebih rendah daripada validasi bukan bukti bahwa model mengalami peningkatan seiring waktu: kedua jendela memiliki perilaku penjualan yang berbeda.

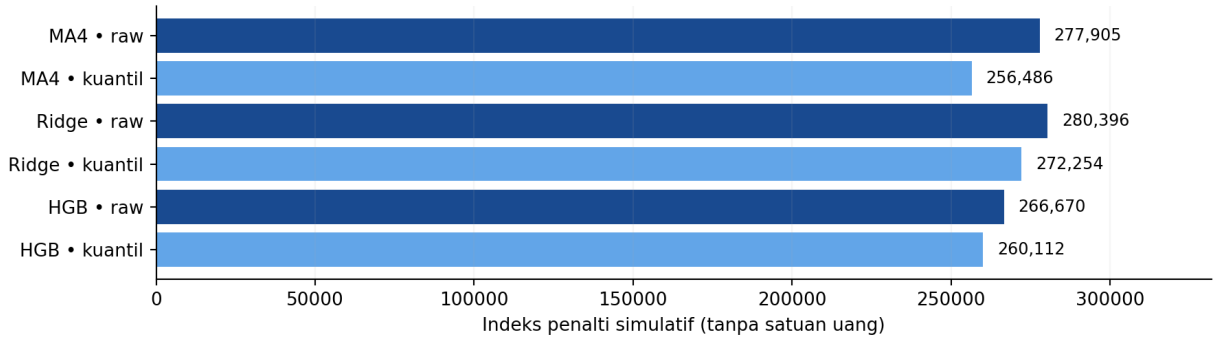
5. Simulasi Keputusan Kapasitas Persediaan

Fase ini menggunakan pendekatan satu-periode ala newsvendor sebagai ilustrasi trade-off. Untuk tiap SKU-minggu, kapasitas hipotetis q dibandingkan dengan unit penjualan tercatat y. Indeks penalti dihitung sebagai $L(q,y)=c_o \cdot \max(q-y,0)+c_u \cdot \max(y-q,0)$. Parameter penalti ($c_u$:$c_o$) adalah asumsi 1:1, 3:1, dan 5:1, bukan parameter biaya perusahaan yang diobservasi.

Terdapat dua aturan kapasitas: (1) menggunakan prediksi mentah yang dibulatkan ke atas; dan (2) menambahkan koreksi kuantil residual bertanda dari 40 minggu validasi saja. Hasil ini tidak memodelkan stok awal, pesanan berjalan, lead time pemasok, maupun biaya dalam rupiah.

METODE / KEBIJAKAN (3:1)	INDEKS PENALTI	CAKUPAN PENJUALAN*
MA4 mentah	277.905	70,07%
MA4 + kuantil residual	256.486	80,00%
Ridge mentah	280.396	69,25%
Ridge + kuantil	272.254	78,93%
HGB mentah	266.670	73,27%
HGB + kuantil	260.112	80,23%

*Proksi yang dihitung terhadap penjualan tercatat, bukan service level atau fill rate operasional.



Gambar 2. Indeks penalti skenario 3:1; lebih rendah bukan berarti biaya riil lebih kecil.

Pada asumsi 3:1, MA4 dengan koreksi kuantil menunjukkan indeks 7,71% lebih rendah dibanding MA4 mentah. Akan tetapi, kapasitas berlebih naik dari 58.962 menjadi 110.185 unit. Lebih penting lagi, rancangan kebijakan dilakukan setelah hasil holdout forecasting dilihat; hasil fase ini post-hoc dan tidak boleh disebut penghematan finansial yang terbukti.

6. Implementasi Sistem dan Pengujian

RETAILCAST diwujudkan sebagai prototipe analitik read-only menggunakan Python, Streamlit, dan data turunan hasil eksperimen. Aplikasi publik menampilkan (1) perbandingan model, (2) analisis produk individual, (3) simulasi kapasitas hipotetis, dan (4) penelitian serta keterbatasan. Tidak ada pembelian, retraining saat pengguna berinteraksi, atau integrasi inventori nyata.

KOMPONEN	BUKTI VERIFIKASI
GitHub	Repositori publik, commit dan workflow tersimpan
Continuous Integration	Screenshot GitHub Actions menunjukkan satu workflow sukses pada branch main
Deployment	Aplikasi publik terbuka di Streamlit Community Cloud
Browser	Screenshot memperlihatkan keempat tab tampil tanpa error
Interaksi kontrol	Perubahan SKU/rasio tidak dapat disimpulkan dari screenshot saja
Audit metodologis	Penjelasan eksplisit mengenai Gate 2A dan desain post-hoc tersedia di dashboard

6.1 Reproduksibilitas

Repo publik menyediakan kode dashboard, CSV hasil eksperimen yang sudah dibekukan, provenance dan checksum, pengujian otomatis, serta konfigurasi dependensi. Reproduksi menyeluruh dari transaksi mentah tetap membutuhkan workbook UCI dan paket audit Fase 2A; repositori aplikasi tidak dengan sendirinya menggantikan seluruh proses penelitian.

Jalur demo: https://retailcast-research-zaky.streamlit.app/
Sumber proyek: https://github.com/zakyilhamf647586-spec/retailcast-research-dashboard

7. Diskusi Kritis dan Keterbatasan

- Kesenjangan target: data mengamati unit penjualan positif, bukan permintaan tak-terbatas atau lost sales; retur tidak dinetokan.
- Duplikat dan transaksi grosir dapat mempengaruhi hasil; status Gate 2A tetap bersyarat tanpa bukti sistem asal.
- Kriteria kontinuitas produk ditetapkan secara eksploratif setelah audit; validitas hanya berlaku untuk populasi 50 SKU terpilih.
- Holdout akhir hanya 12 minggu; bootstrap deskriptif tidak menggantikan validasi eksternal atau pengujian pra-registrasi.
- Simulasi kebijakan dibuat setelah hasil holdout diperiksa; angka −7,71% bukan hasil uji kebijakan baru yang independen.
- Rasio penalti, kapasitas, dan cakupan hanyalah asumsi; laporan tidak memuat biaya rupiah atau rekomendasi pembelian.
- Dataset historis Inggris tahun 2009–2011 tidak menjamin transfer ke ritel Indonesia saat ini.

8. Kesimpulan dan Implikasi

Dalam definisi sampel dan protokol yang dibekukan, MA4 merupakan pilihan utama karena mencatat WAPE validasi terendah, 73,6334%. Ridge memberikan hasil holdout numerik yang sedikit lebih baik, 53,4649% versus 54,0980% milik MA4, tetapi selisih tersebut belum membuktikan keunggulan umum. Perbedaan peringkat metrik memperlihatkan pentingnya penetapan tujuan evaluasi sebelum eksperimen. Penilaian industri seharusnya mempertimbangkan akurasi, variabilitas biaya keputusan, kualitas data, ketidakpastian, serta kebutuhan operasional yang belum direpresentasikan oleh dataset ini.

Simulasi menunjukkan bahwa asumsi penalti dan kebijakan penyesuaian dapat mengubah peringkat metode dalam sebuah indeks biaya hipotetis. Karena dikembangkan post-hoc, hasil tersebut tepat dipresentasikan sebagai eksplorasi risiko dan trade-off, bukan bukti optimasi inventori perusahaan. Kontribusi RETAILCAST saat ini adalah prototipe penelitian yang transparan, dapat diperiksa, dan berfungsi sebagai demonstrasi kemampuan end-to-end data science serta perangkat lunak.

8.1 Arah penelitian berikutnya

- Mendapatkan data stok, stockout, lead time, master produk, dan biaya dari mitra industri; melakukan rekonsiliasi duplikat serta retur.
- Mendefinisikan protokol baru dan membekukan kebijakan sebelum melihat periode uji independen yang baru.
- Mengembangkan forecast multi-horizon, segmentasi permintaan intermittent, dan evaluasi risiko pada level SKU.
- Menilai manfaat keputusan menggunakan biaya aktual, constraint kapasitas, serta uji lapangan terkendali sebelum klaim produksi.

Daftar pustaka

[1] Chen, D. (2012). Online Retail II [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5CG6D. Lisensi CC BY 4.0.

[2] Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. International Journal of Forecasting, 22(4), 679–688. https://doi.org/10.1016/j.ijforecast.2006.03.001.

[3] MIT OpenCourseWare. (2014). Newsvendor Inventory Problem. D-Lab: Supply Chains. https://ocw.mit.edu/courses/15-772j-d-lab-supply-chains-fall-2014/6952be57b43aa185119c6f114908bcc5_MIT15_772JF14_Newsboy.pdf.

Catatan status proyek

Prototipe penelitian telah dipublikasikan pada Streamlit. Audit Fase 2A tetap bersyarat, dan simulasi Fase 4 tetap eksploratif/post-hoc; keduanya tidak boleh dianggap tervalidasi secara operasional.